

Informe del análisis realizado

Introducción

El conjunto de datos final está compuesto por 45.049 películas, constituyendo una muestra amplia y representativa de la industria cinematográfica internacional. Para su construcción se integraron dos conjuntos de datos mediante la clave `imdb_id`, combinando información económica, técnica y descriptiva de cada película.

Durante la fase de preparación se detectaron inconsistencias en el identificador `imdb_id`, debido a diferencias en el tipo de dato y a la presencia de espacios en blanco. Tras normalizar los identificadores y realizar una unión interna (`inner join`), se obtuvo un conjunto de datos consistente y preparado para el análisis.

Asimismo, se eliminaron registros duplicados, se trataron los valores nulos, se homogeneizaron los tipos de datos y se sustituyeron los valores faltantes en las variables categóricas por el valor "Unknown". En las variables económicas (`budget` y `revenue`), los valores iguales a cero se consideraron datos ausentes para evitar distorsiones en el análisis financiero.

Análisis descriptivo

Variables económicas

El análisis descriptivo muestra una elevada dispersión en las variables económicas, consecuencia de la coexistencia de producciones independientes y grandes superproducciones.

Variable	Valor
Presupuesto medio	4,64 millones
Recaudación media	11,31 millones
Beneficio medio	6,66 millones
Presupuesto máximo	460 millones
Recaudación máxima	2.787,97 millones
Beneficio máximo	2.550,97 millones

La distribución de estas variables presenta una fuerte asimetría positiva, donde un reducido número de películas concentra gran parte de la inversión y de la recaudación total.

Rentabilidad (ROI)

El análisis del retorno de la inversión (ROI) evidencia una enorme variabilidad entre películas.

Media: 62,7

Desviación estándar: 12.983

Mediana: 0

Tercer cuartil: 0

Estos resultados indican que una parte importante del conjunto de datos no dispone de información presupuestaria o no obtuvo beneficios suficientes para generar un ROI positivo. En consecuencia, esta variable está fuertemente influenciada por valores extremos.

Duración de las películas

La duración media de las películas es de 93 minutos, valor que coincide con la duración habitual del cine comercial.

Además:

- El 50 % de las películas tiene una duración comprendida entre 85 y 106 minutos.
- Existen algunos valores atípicos de hasta 720 minutos, probablemente asociados a miniseries, documentales o producciones especiales.

El análisis de correlación demuestra que la duración apenas influye en la recaudación, el presupuesto o la popularidad.

Valoraciones de los usuarios

La valoración media registrada en TMDB es de 5,62 sobre 10, con una desviación estándar de 1,92.

La mayoría de las películas reciben puntuaciones comprendidas entre 5 y 7 puntos, lo que indica una concentración de valoraciones intermedias.

Por su parte, el número medio de votos es de 110,69, aunque existen películas que superan los 14.000 votos, reflejando que solo un pequeño grupo de producciones concentra gran parte de la atención de los usuarios.

Análisis de correlación

Variables	Correlación
Revenue – Profit	0,975
Revenue – Vote Count	0,812
Budget – Revenue	0,756
Profit – Vote Count	0,774
Budget – Vote Count	0,666

La matriz de correlación permitió identificar las relaciones más relevantes entre las variables analizadas.

Los resultados muestran que las películas con mayor presupuesto tienden a obtener mayores ingresos y reciben un mayor número de valoraciones por parte de los usuarios.

El gráfico de dispersión Budget vs Revenue confirma esta tendencia. Aunque existe una clara relación positiva entre ambas variables, también se observa una importante dispersión: algunas películas con presupuestos elevados obtienen ingresos modestos, mientras que otras con presupuestos moderados alcanzan recaudaciones muy superiores.

Esto indica que el presupuesto aumenta las probabilidades de éxito económico, pero no lo garantiza, ya que intervienen otros factores como el marketing, la distribución, la aceptación del público o la notoriedad de la franquicia.

Relaciones moderadas

La variable Popularity presenta correlaciones moderadas con:

Revenue: 0,506

Vote Count: 0,560

Budget: 0,457

Estos resultados indican que las películas más populares suelen generar mayores ingresos y una mayor interacción por parte de los usuarios.

Relaciones débiles

Las correlaciones de Vote Average con el resto de variables son reducidas:

Budget: 0,071

Revenue: 0,085

Vote Count: 0,124

Popularity: 0,155

Esto demuestra que una película mejor valorada no necesariamente obtiene una mayor recaudación ni dispone de un mayor presupuesto.

De igual forma, la variable Runtime presenta correlaciones muy bajas (entre 0,13 y 0,17), indicando que la duración apenas influye en el rendimiento económico o en la valoración del público.

Análisis de las variables categóricas

Idioma original

El idioma predominante es claramente el inglés.

Idioma Número de películas

Inglés 31.920

Francés 2.429

Italiano 1.527

Japonés 1.337

Alemán 1.069

Estos resultados reflejan el predominio de las producciones anglosajonas dentro del conjunto de datos.

Géneros

Los géneros con mayor representación son:

Género Nº de películas

Drama 4.879

Comedy 3.427

Documentary 2.889

La elevada presencia de combinaciones de géneros evidencia la diversidad de las producciones cinematográficas actuales.

Productoras

Las productoras con mayor presencia en el conjunto de datos son:

Metro-Goldwyn-Mayer

Warner Bros. Pictures

Paramount

20th Century Fox

Universal Pictures

La categoría Unknown incluye 5.560 registros, lo que indica la existencia de información incompleta para una parte de las películas.

Países de producción

Estados Unidos concentra la mayor parte de la producción cinematográfica.

País	Nº de películas
------	-----------------

Estados Unidos	18.983
----------------	--------

Reino Unido	2.326
-------------	-------

Francia	1.673
---------	-------

Japón	1.378
-------	-------

Italia	1.173
--------	-------

Estos resultados reflejan el liderazgo histórico de la industria cinematográfica estadounidense, seguida por otros países con una importante tradición audiovisual.

Conclusiones

El proceso de limpieza e integración permitió obtener un conjunto de datos fiable y consistente para el análisis exploratorio. La normalización de los identificadores, el tratamiento de valores nulos y la eliminación de registros duplicados mejoraron significativamente la calidad de la información.

Los resultados ponen de manifiesto una elevada heterogeneidad en la industria cinematográfica. La existencia de una correlación positiva entre presupuesto y recaudación (0,756) confirma que una mayor inversión suele traducirse en mayores ingresos; sin embargo, el éxito comercial también depende de factores como la popularidad, la estrategia de marketing, la distribución y la aceptación del público.

La relación entre recaudación y número de votos (0,812) demuestra que las películas con mayor éxito económico generan también una mayor participación de los usuarios, mientras que la valoración media apenas guarda relación con el rendimiento financiero.

El análisis descriptivo confirma el predominio de las producciones estadounidenses y del idioma inglés, así como la importancia de los géneros Drama, Comedy y Documentary dentro del conjunto analizado.

Por otra parte, la elevada cantidad de registros sin información económica completa pone de manifiesto la necesidad de seguir mejorando la calidad de los datos para futuros estudios. En este sentido, sería recomendable descomponer variables multivalor como `genres`, `production_companies` y `production_countries` para realizar análisis más detallados por género, estudio o país.

Finalmente, la incorporación de indicadores derivados como Profit y ROI permitió evaluar la rentabilidad de las películas desde una perspectiva más amplia que la recaudación total. El conjunto de datos obtenido constituye una base sólida para desarrollar modelos predictivos, construir dashboards interactivos y apoyar la toma de decisiones en el ámbito de la industria cinematográfica.